Entrega 4: Despliegue en Cloud Run y Cloud Pub/Sub

Desplegar la aplicación de las entregas anteriores sobre Cloud Run e integrar Cloud Pub/Sub para ejecutar tareas asíncronas y comunicar el backend con los workers. Se parte de la base de código y las funcionalidades existentes.

1. Despliegue y escalamiento

Desplegar **tres servicios independientes en Cloud Run**, con imágenes publicadas en Artifact Registry.

Servicio	Responsabilidad	Máximo de instancias configurado
Frontend	Servir la interfaz de la aplicación.	3
Backend	Exponer la API y publicar tareas en Pub/Sub.	3
Workers	Recibir mensajes y ejecutar tareas asíncronas.	3

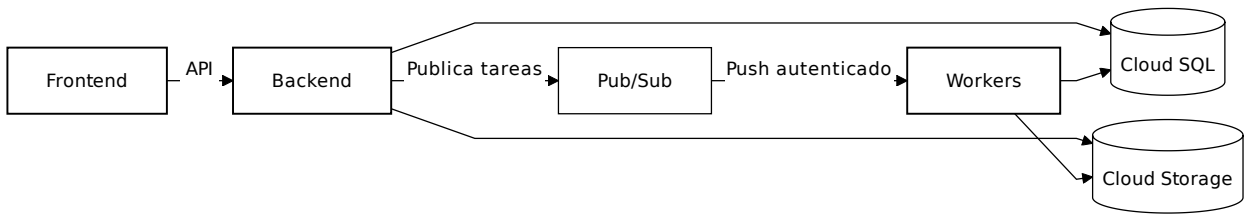
Configurar el escalamiento automático con **máximo de 3 instancias por servicio**, con un contenedor de aplicación por instancia. No se exige mantener tres instancias activas permanentemente.

Documentar región, mínimo de instancias, CPU, memoria, concurrencia y tiempo máximo de solicitud de cada servicio. Las réplicas deben operar sin depender del almacenamiento local para persistir información.

Conectar el frontend con el backend desplegado, configurar CORS cuando corresponda y conservar la autenticación existente. Backend y workers deben acceder a Cloud SQL y Cloud Storage según sus responsabilidades.

> El requisito se verifica sobre el límite configurado. Cloud Run puede superarlo temporalmente, según su documentación de escalamiento.

Arquitectura general



Frontend, backend y workers en Cloud Run · Máximo configurado de 3 instancias por servicio.
Pub/Sub conecta el backend con los workers mediante un topic y una suscripción push.

2. Tareas asíncronas mediante Cloud Pub/Sub

Sustituir el mecanismo de mensajería previo por un topic de Pub/Sub y una **suscripción push autenticada** dirigida al servicio de workers.

El backend debe publicar tareas y responder sin esperar su ejecución. Pub/Sub entregará cada mensaje a un worker, que ejecutará la tarea y persistirá su estado y resultado según corresponda. La aplicación debe permitir verificar su finalización.

Confirmar los mensajes después de completar y persistir el procesamiento. Configurar tiempos compatibles y tolerar reentregas sin duplicar los efectos de una tarea.

3. Configuración y acceso

- Utilizar cuentas de servicio con permisos mínimos para los recursos requeridos.
- Restringir la invocación de workers mediante IAM y autorizar la identidad de la suscripción push.
- Gestionar configuración mediante variables de entorno y secretos mediante Secret Manager, sin claves ni contraseñas en el repositorio o las imágenes.

4. Entregables y verificación

Entregar en el repositorio:

- **Guía reproducible de despliegue**, con comandos o scripts, imágenes, configuración de servicios, topic, suscripción y permisos.
- **Diagrama actualizado**, con los componentes desplegados y sus conexiones.
- **Evidencias de funcionamiento**, con URL de frontend y backend, límites de instancias y registros que permitan seguir una tarea desde su publicación hasta su finalización.
- **Verificación breve del escalamiento**, con métricas del número de instancias ante solicitudes concurrentes y mensajes pendientes, utilizando una carga controlada.
- **Video de sustentación de máximo 20 minutos**, con enlace accesible para el evaluador. Debe demostrar la aplicación desplegada, el recorrido completo de una tarea por Pub/Sub y los workers, la configuración y evidencia de escalamiento, y las decisiones de acceso y permisos.

5. Rúbrica de evaluación

La calificación suma **0 a 100 puntos**. Asignar uno de los tres puntajes por criterio según las evidencias.

Criterio	Cumplimiento completo	Cumplimiento parcial	Sin cumplimiento
Despliegue e integración - 30 puntos	**30** · Tres servicios operativos e integrados con sus dependencias.	**15** · Despliegue con fallas parciales de integración.	**0** · Aplicación no operativa en Cloud Run.
Pub/Sub y workers - 25 puntos	**25** · Flujo completo, autenticado, con confirmación y reentregas sin efectos duplicados.	**12** · Ejecución demostrada; confirmación o reentregas incompletas.	**0** · Sin ejecución demostrada mediante Pub/Sub.
Escalamiento - 20 puntos	**20** · Máximo de 3 por servicio y escalamiento demostrado con métricas.	**10** · Límites correctos; verificación incompleta.	**0** · Límites incorrectos o sin evidencia.
Configuración y acceso - 15 puntos	**15** · Permisos mínimos, workers protegidos y secretos gestionados correctamente.	**7** · Controles incompletos, sin credenciales expuestas.	**0** · Credenciales expuestas o workers sin protección.
Documentación y video - 10 puntos	**10** · Guía reproducible, diagrama coherente y video de hasta 20 minutos con las demostraciones exigidas.	**5** · Entregables incompletos o video mayor a 20 minutos.	**0** · Sin documentación ni video verificables.